Spiderweb DigitalSkola

Juli 2024

PROJECT 4
STEP BY STEP

Prepared By:

Spiderweb team

Kelompok 5

FTDE - 01 DigitalSkola Bootcamp

Spiderweb

DigitalSkola

TEAM MEMBER

KELOMPOK 5 FTDE-01

Hafidha Harfiana

Humairoh

Hermawan

I Gusti Agung Krishna

I Putu Ferry Wstika

Fenny Inriana

FTDE-01 DigitalSkola

System Requirements :

1. installkafkadockerzookeperdenganmenontonvideo:
   https://www.youtube.com/watch?v=Zq8aMrRnvQE

   Kafka zookeper di docker sudah up and running

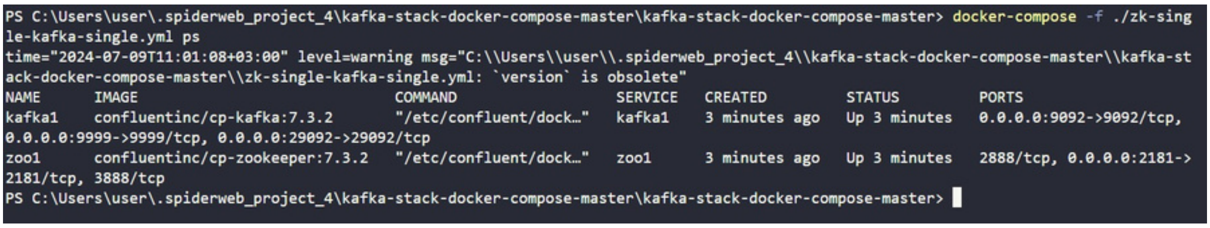

2. running mongodb sudah dilakukan melalui docker dan git bash

3. running postgres melalui docker sudah dilakukan

4. Connect database server PostgreSQL sudah dilakukan :

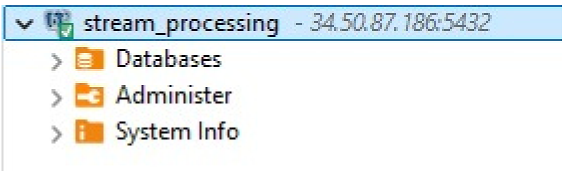

Langkah - langkah :

1. Runningairflowdenganmenontonvideoyoutube:
   https://youtu.be/Sva8rDtlWi4?si=sdooDbnn2aKJ0Lzp

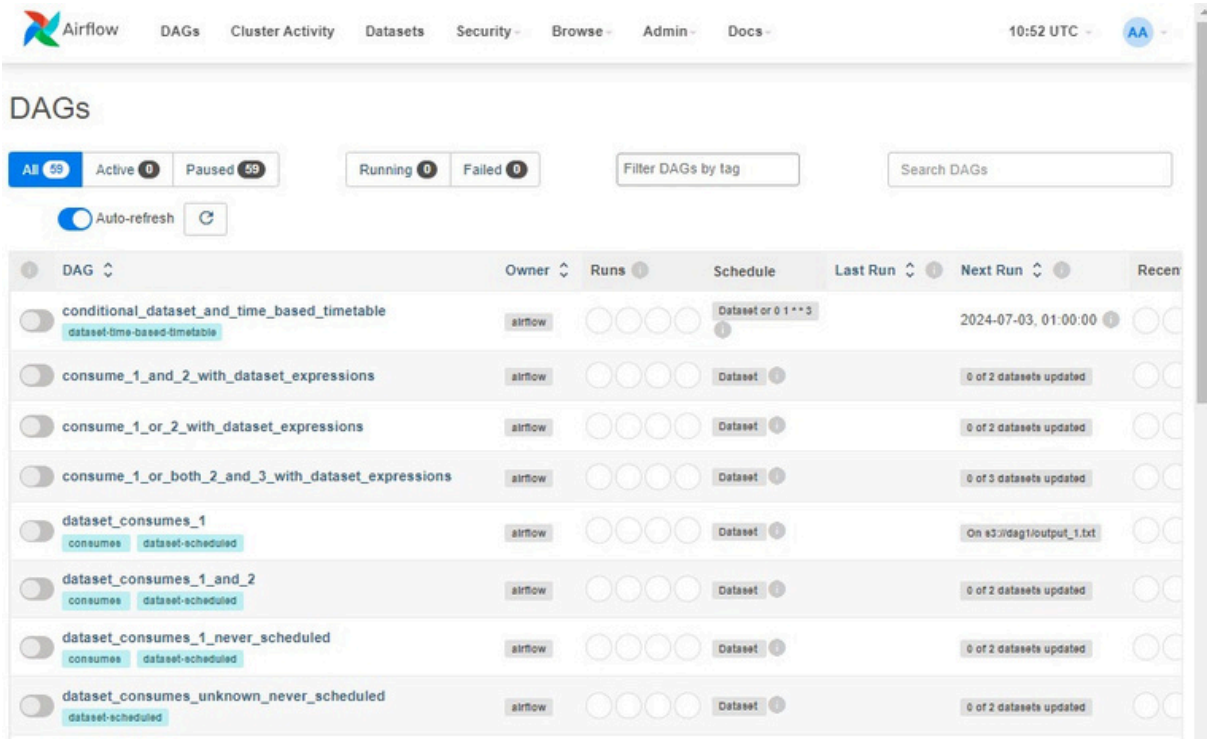

Dibawah ini adalah bukti airflow sudah running di docker. saatnya untuk memberikan file DAG python untuk mengkoneksikan dengan server postgre SQL

2. Lalu membuat file DAG python untuk mengorkestrasi data dari PostgreSQL ke Apache Airflow. File python bernama “load_postgres_table.py”. Setelah itu trigger DAG di UI Airflow.

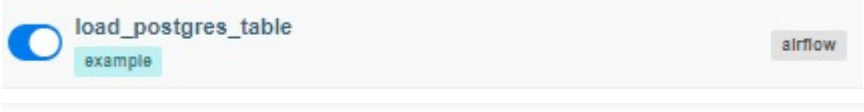

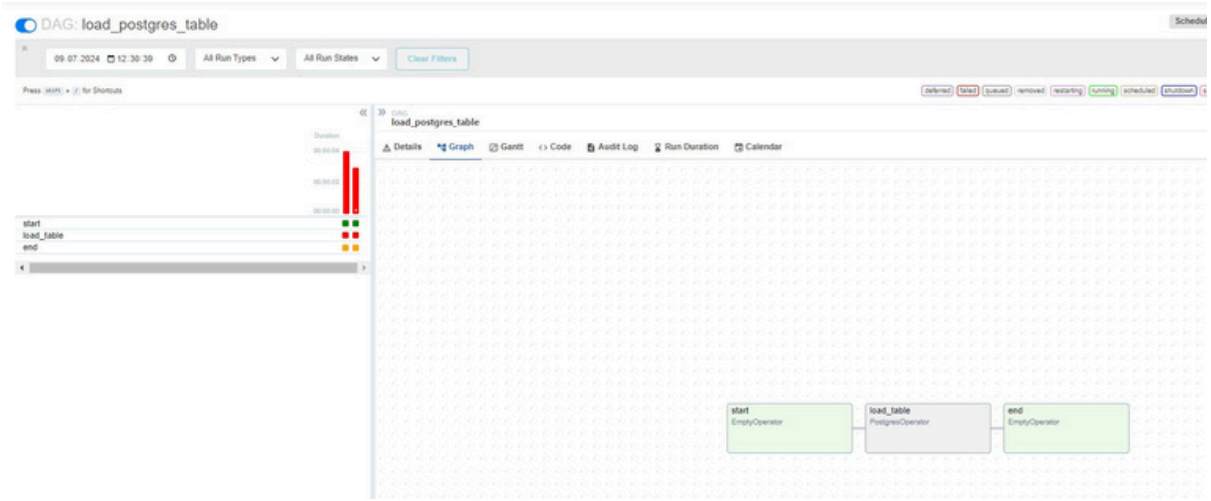

3. Selanjutnya adalah mengerjakan Data Pipeline.
Kami running Tes-Model.ipynb melalui Jupyter lokal untuk akses file FraudModel.py

dari folder modelling.

```
[60]:
from modelling import FraudModel
```

4. Sekarang kami akan memakai modelnya ambil dari data transaksi pada file FraudModel.py untuk inputan data

```
[62]:
#parameter inputan data
new_data = {
    'step': 1,
    'type': 'PAYMENT',
    'amount': 9839.64,
    'oldbalanceOrg': 170136.0,
    'newbalanceOrig': 160296.36,
    'oldbalanceDest': 0.0,
    'newbalanceDest': 0.0
}

new_data
```

```
[62]:
{'step': 1,
 'type': 'PAYMENT',
 'amount': 9839.64,
 'oldbalanceOrg': 170136.0,
 'newbalanceOrig': 160296.36,
 'oldbalanceDest': 0.0,
 'newbalanceDest': 0.0}
```

5. Lalu kami akan memakai modelnya ambil dari data transaksi pada file FraudModel.py untuk inputan path

[72]:

```
#parameter inputan path
import os

path = os.getcwd()
path = path + "\\modelling\\"
path
```

[72]:

```
'C:\\Users\\user\\DE - STREAM PROCESSING\\modelling\\'
```

dari sini kita dapat melihat bahwa posisi FraudModel.py sudah benar, yaitu pada folder modelling.

Namun, kami mendapatkan sebuah insight bahwa banyak library pada folder ‘DE - STREAM PROCESSING’ yang memiliki versi berbeda dengan library yang dimiliki oleh Jupyter lokal (Anaconda) oleh karena itu kami akan membuat virtual environment (venv) di VSCode dan melanjutkan codingan di VSCode. Dengan virtual environment, kami bisa mengisolasi versi Python dan library yang digunakan dalam proyek kami tanpa mempengaruhi versi global Python di sistem kami

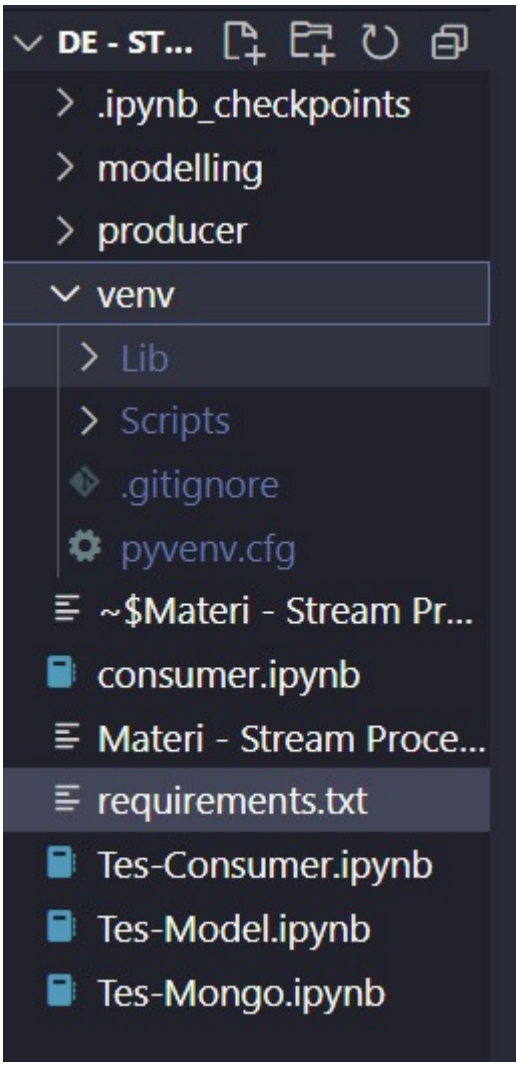

virtual environemnt sudah dipasang.

6. Kamimelakukananalisisbahwaterdapat9LibraryPythonyangdigunakandifolder ‘DE - STREAM PROCESSING’ yang harus kami install terlebih dahulu untuk menjalankan kode.

```
(venv) PS C:\Users\user\Downloads\DE - STREAM PROCESSING
> pip install -r requirements.txt
(venv) PS C:\Users\user\Downloads\DE - STREAM PROCESSING
> pip freeze
```

7. Kami akan running file Tes-Model.ipynb dan kode berhasil dijalankan.
8. Kami masuk ke dalam folder producer dan menemui fakta connection PostgreSQL dengan rincian :

   ip : 34.50.87.186
   db : stream_processing
   username : ftde01
   password : ftde01!@#

   Lalu kami mengakses datadump.ipynb untuk masukin data PostgreSQL ini ke database lokal. Lalu kami akan melakukan running pada file ini dengan hasil

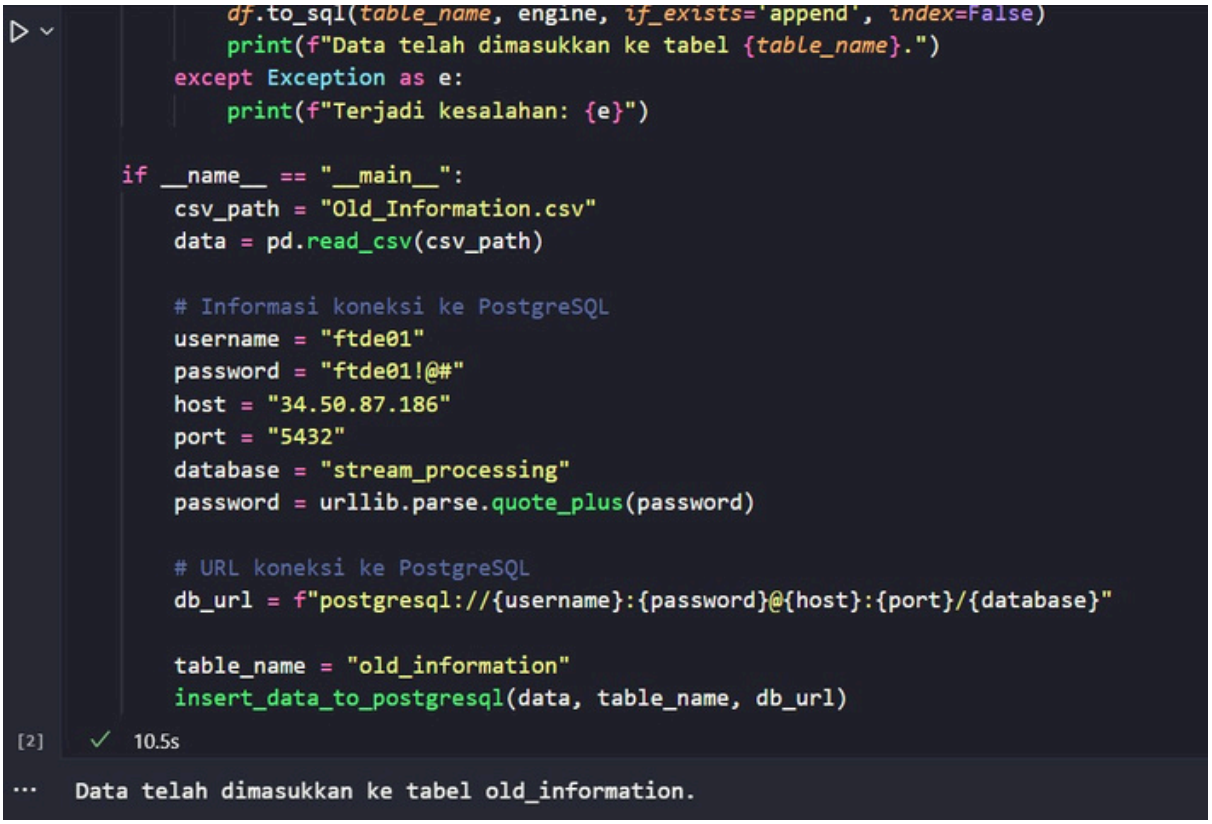

Data dump berhasil di running dan success.

9. Kami akan membuka folder producer dan mengakses file producer.ipynb untuk melakukan simulasi transaksi yang terjadi di mobile dan terjadi di kafka. Jadi ada producer, lalu lempar data ke kafka dengan nama ftde01-project4.

   Ketika running producer, terdapat error dengan keterangan

   ModuleNotFoundError: No module named 'kafka.vendor.six.moves'

   Error ModuleNotFoundError: No module named 'kafka.vendor.six.moves' terjadi karena Kafka library yang digunakan mencoba mengimpor modul yang seharusnya terdapat dalam versi Kafka yang lebih lama.

   Oleh karena itu kami install kafka-python-ng untuk menghindari error ini berdasarkan sumber : https://stackoverflow.com/questions/77287622/modulenotfounderror-no-module-named-kafka-vendor-six-moves-in-dockerized-djan . Namun, terdapat error lagi : **NoBrokersAvailable**: NoBrokersAvailable. Oleh karena itu kami menambahkan api_version

   Kami mengubah kode menjadi kode yang menyesuaikan versi Python venv yang terbaru yaitu Python 3.12.2. Running berhasil

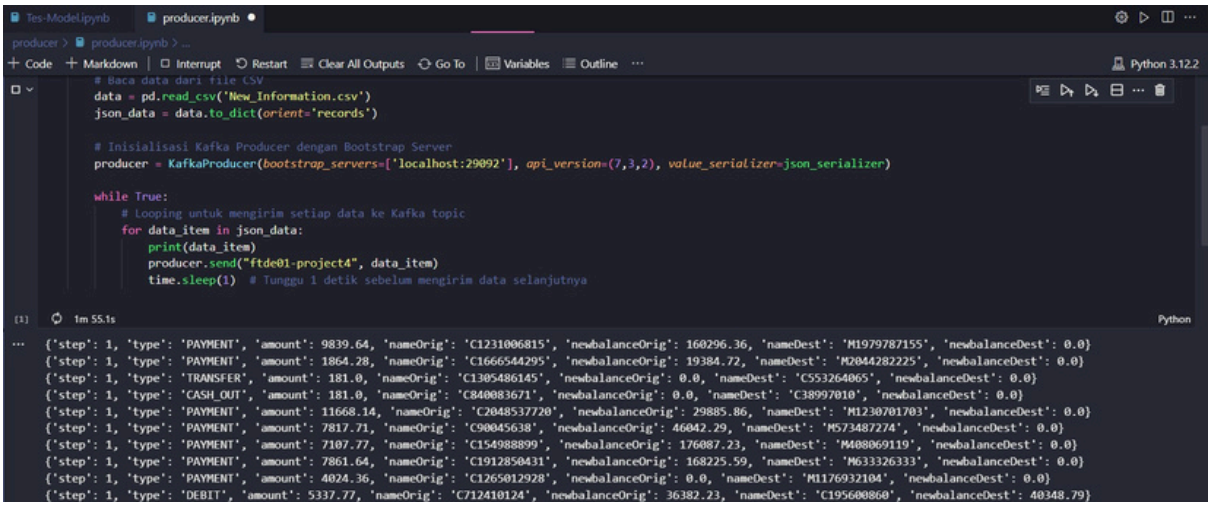

after 60.0 secs.

10. Lalu kami akan mengambil data ini di Kafka, sehingga kami mengakses notebook consumer.ipynb dan notebook Tes-Consumer.ipynb. Pada consumer.ipynb kami menyesuaikan kode agar sesuai dengan versi Python terbaru 3.12.2. Dan kode blok ini berhasil dijalankan (data tersebut berhasil ditangkap)

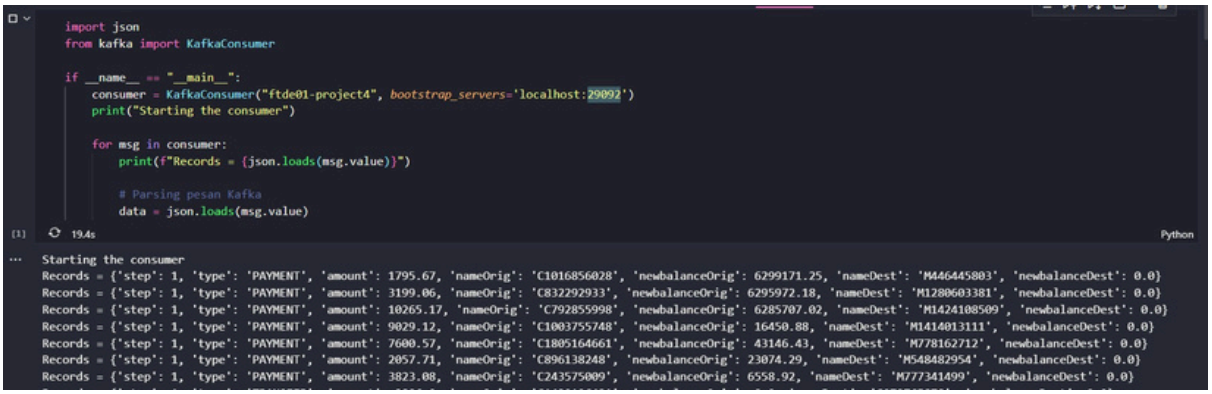

Pada saat ini kami akan memberhentikan producer.ipynb untuk mendapat data hasil producer yang secukupnya.

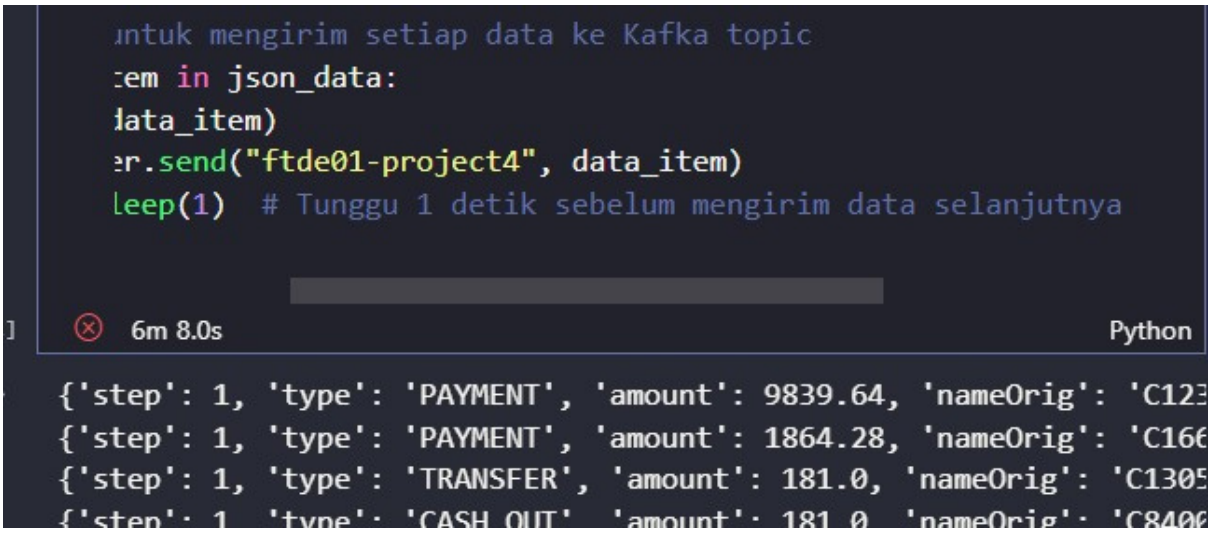

lalu data sudah cukup diambil oleh consumer, kami akan mematikan proses runningnya

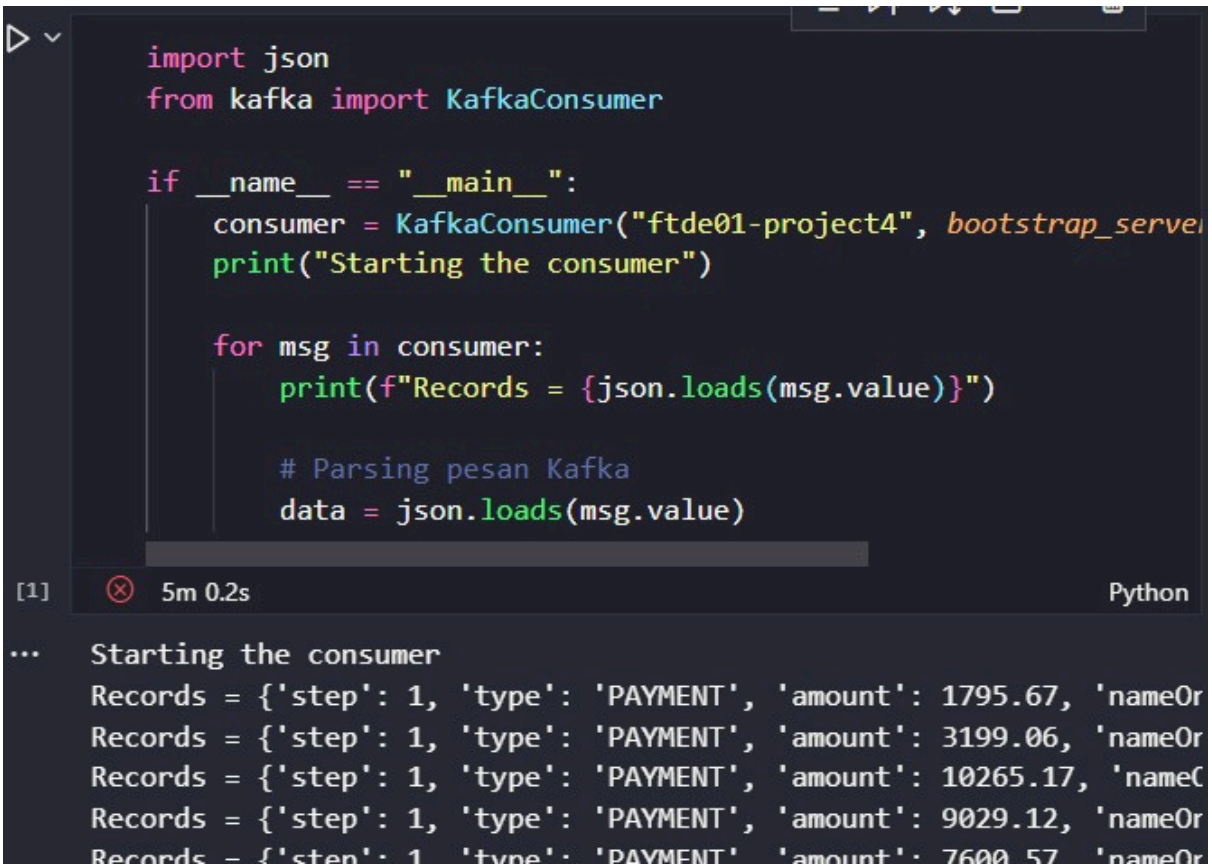

```
import json
from kafka import KafkaConsumer

if __name__ == "__main__":
    consumer = KafkaConsumer("ftde01-project4", bootstrap_serve
    print("Starting the consumer")

    for msg in consumer:
        print(f"Records = {json.loads(msg.value)}")

        # Parsing pesan Kafka
        data = json.loads(msg.value)
```

[1] ⊗ 5m 0.2s Python

```
Starting the consumer
Records = {'step': 1, 'type': 'PAYMENT', 'amount': 1795.67, 'nameOr
Records = {'step': 1, 'type': 'PAYMENT', 'amount': 3199.06, 'nameOr
Records = {'step': 1, 'type': 'PAYMENT', 'amount': 10265.17, 'nameO
Records = {'step': 1, 'type': 'PAYMENT', 'amount': 9029.12, 'nameOr
Records = {'step': 1, 'type': 'PAYMENT', 'amount': 7600.57, 'nameOr
```

11. Kami mengeksekusi setiap cell di Tes-Consumer. Kami berhasil running di kedua kode blok ini :

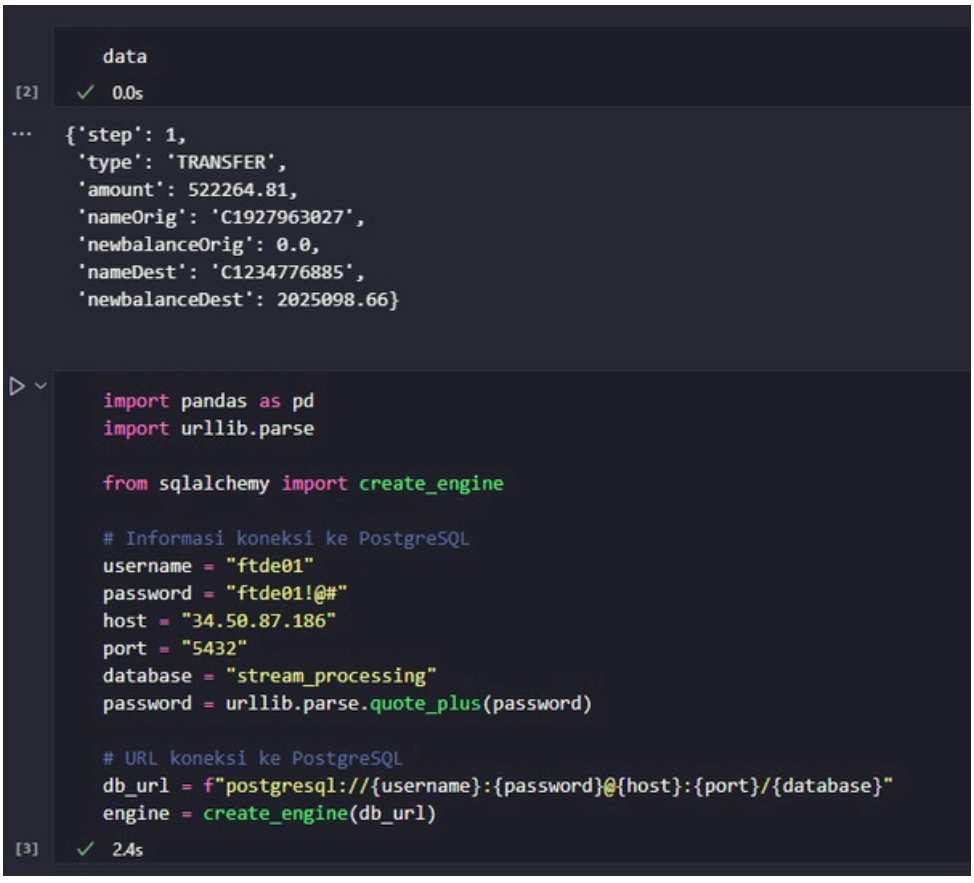

```
data
```

[2] ✓ 0.0s

```
{'step': 1,
 'type': 'TRANSFER',
 'amount': 522264.81,
 'nameOrig': 'C1927963027',
 'newbalanceOrig': 0.0,
 'nameDest': 'C1234776885',
 'newbalanceDest': 2025098.66}
```

```
import pandas as pd
import urllib.parse

from sqlalchemy import create_engine

# Informasi koneksi ke PostgreSQL
username = "ftde01"
password = "ftde01!@#"
host = "34.50.87.186"
port = "5432"
database = "stream_processing"
password = urllib.parse.quote_plus(password)

# URL koneksi ke PostgreSQL
db_url = f"postgresql://{username}:{password}@{host}:{port}/{database}"
engine = create_engine(db_url)
```

[3] ✓ 2.4s

Namun tidak dengan

```
df = pd.read_sql_query('SELECT * FROM old_information;', engine)
df.head(5)
```

0.1s

karena error : AttributeError: 'Engine' object has no attribute 'cursor'. Maka dari itu kami mencoba solusi lain dengan mencari solusi pada stack overflow dan kami sudah menemukan solusinya lalu running berhasil :

```
connection = engine.raw_connection()
df = pd.read_sql_query('SELECT * FROM old_information;', con=connection)
df.head(5)
```

[12] ✓ 8.6s

```
:\Users\user\AppData\Local\Temp\ipykernel_21712\3931741001.py:2: UserWarning: pa
  df = pd.read_sql_query('SELECT * FROM old_information;', con=connection)
```

	nameOrig	oldbalanceOrg	nameDest	oldbalanceDest
0	C1231006815	170136.0	M1979787155	0.0
1	C1666544295	21249.0	M2044282225	0.0
2	C1305486145	181.0	C553264065	0.0
3	C840083671	181.0	C38997010	21182.0
4	C2048537720	41554.0	M1230701703	0.0

12. Consumer sudah berhasil kami ambil, kami akan melakukan join dengan mengubah data producer dalam bentuk dict ke dataframe.

Join Data From Producer Kafka and Database PostgreSQL

```
produder = pd.DataFrame([data])
produder
```

[8] ✓ 0.0s

	step	type	amount	nameOrig	newbalanceOrig	nameDest	newbalanceDest
0	1	DEBIT	4874.49	C811207775	0.0	C1971489295	0.0

```
data = produder.merge(df, how='inner', on=['nameOrig','nameDest'])
predict = data.drop(['nameOrig','nameDest'], axis=1)
predict = predict.to_dict('index')[0]
predict
```

[9] ✓ 0.0s

```
{'step': 1,
 'type': 'DEBIT',
 'amount': 4874.49,
 'newbalanceOrig': 0.0,
 'newbalanceDest': 0.0,
 'oldbalanceOrg': 153.0,
 'oldbalanceDest': 253104.0}
```

Join data sudah berhasil dilakukan, lalu kami akan melakukan prediksi Fraud :

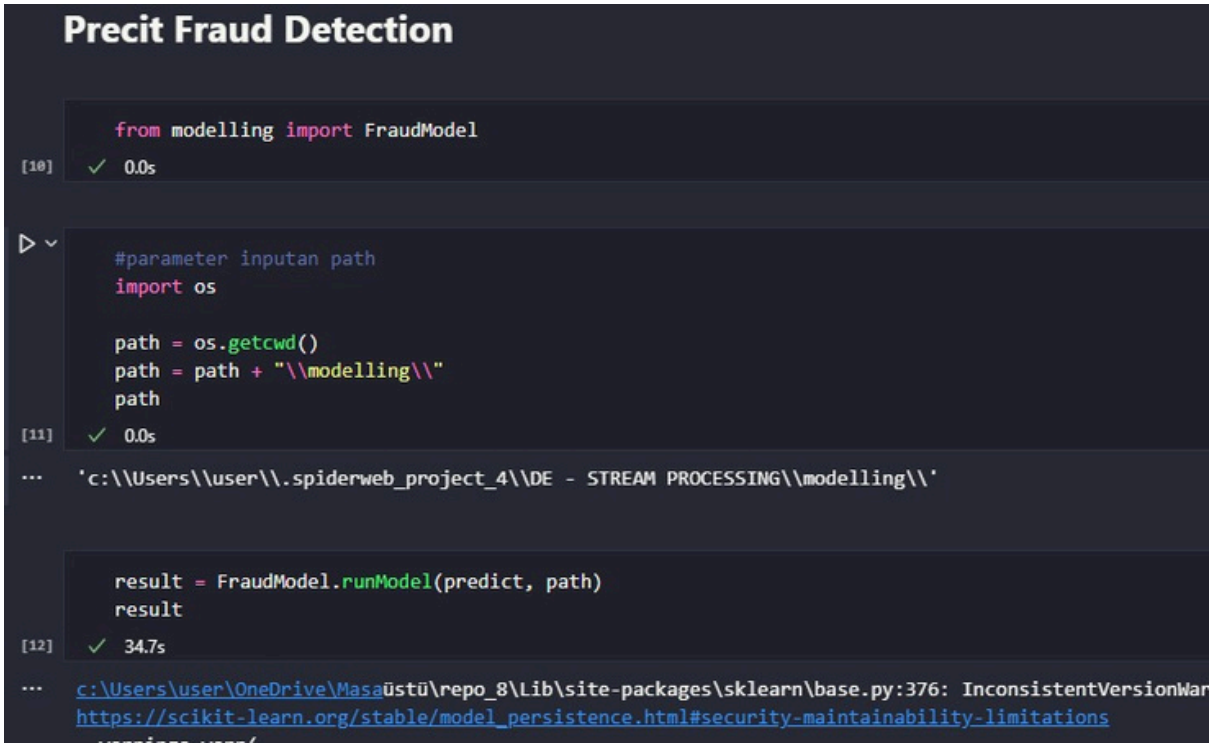

Prediksi berhasil dilakukan :

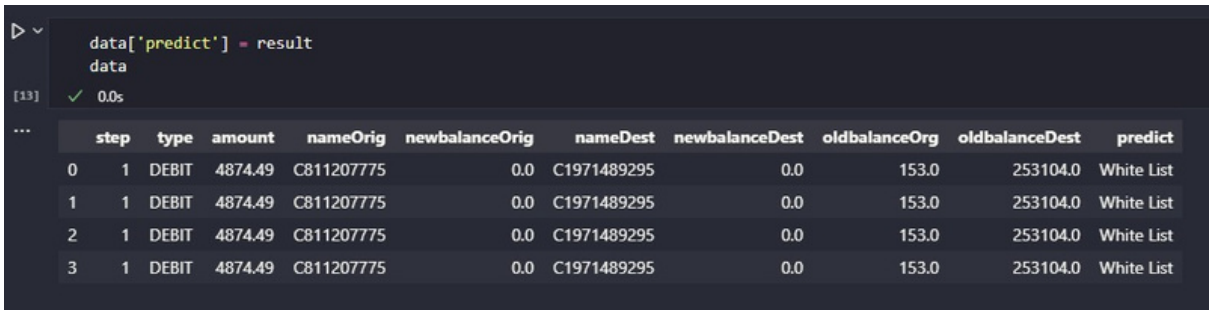

```
data['predict'] = result
data
```

[13] ✓ 0.0s

	step	type	amount	nameOrig	newbalanceOrig	nameDest	newbalanceDest	oldbalanceOrg	oldbalanceDest	predict
0	1	DEBIT	4874.49	C811207775	0.0	C1971489295	0.0	153.0	253104.0	White List
1	1	DEBIT	4874.49	C811207775	0.0	C1971489295	0.0	153.0	253104.0	White List
2	1	DEBIT	4874.49	C811207775	0.0	C1971489295	0.0	153.0	253104.0	White List
3	1	DEBIT	4874.49	C811207775	0.0	C1971489295	0.0	153.0	253104.0	White List

13. Langkah terakhir adalah insert ke MongoDB kami set terlebih dahulu username dan passwordnya :

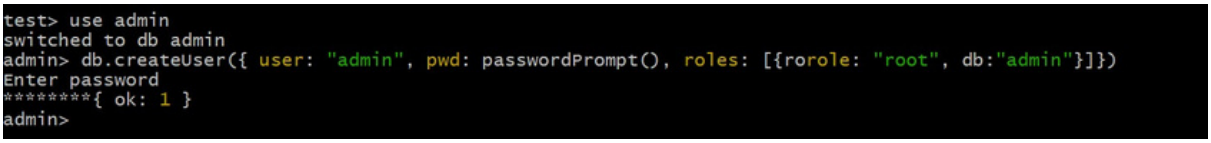

```
test> use admin
switched to db admin
admin> db.createUser({ user: "admin", pwd: passwordPrompt(), roles: [{rorole: "root", db:"admin"}]})
Enter password
********{ ok: 1 }
admin>
```

```python
from pymongo import MongoClient

# Mengatur koneksi ke MongoDB
mongo_client = MongoClient("mongodb://admin:password@localhost:2717")

db = mongo_client["ftde01"]
collection = db["project4-collection"]

if isinstance(data.to_dict('index')[0], list):
    collection.insert_many(data.to_dict('index')[0])
else:
    collection.insert_one(data.to_dict('index')[0])
    print("Data telah disimpan ke MongoDB")
```

[25] ✓ 0.1s

```
Data telah disimpan ke MongoDB
```

Kami sudah menarik datanya dari MongoDB

```python
mongo_client = MongoClient("mongodb://admin:password@localhost:2717/")
db = mongo_client["ftde01"]
collection = db["project4-collection"]

# Membaca data dari MongoDB ke dalam list of dictionaries
data_from_mongo = list(collection.find())

# Membaca data ke dalam DataFrame
df = pd.DataFrame(data_from_mongo)
df
```

[26] ✓ 0.0s

	_id	step	type	amount	nameOrig	newbalanceOrig	nameDest	newbalanceDest	oldbalanceOrg	oldbalanceDest	predict
0	66900df2c091f21df1b32d66	1	DEBIT	4874.49	C811207775	0.0	C1971489295	0.0	153.0	253104.0	White List

Dari data ini dipindahkan lagi ke dalam dalam google sheet. lalu visualisasikan ke google studio.


Thank
you